

Classification d'images de déchets recyclables par apprentissage profond

Projet de fin de module TDMM

Amraoui Hind Khadly Zainab

Département d'Informatique, Master Science de Données

Septembre 2026

Plan de la présentation

- 1 Définition du problème
- 2 Data Collection
- 3 Data Exploration
- 4 Data Preprocessing / Cleaning
- 5 Data Augmentation
- 6 Split des données
- 7 Choix / conception du modèle
- 8 Évaluation avant optimisation
- 9 Détail de la référence avant optimisation
- 10 Optimisation des hyperparamètres
- 11 Évaluation Transfer Learning ResNet-18
- 12 Dynamique d'entraînement du modèle proxy
- 13 Benchmarking matériel : CPU vs. GPU
- 14 Évaluation finale
- 15 Discussion
- 16 Conclusion

1. Définition du problème

Objectif

Classer automatiquement une image de déchet dans l'une de 6 catégories recyclables, pour assister le tri sélectif.

- **6 catégories** : carton, verre, métal, papier, plastique, déchets divers
- **Jeu de données** : *Garbage Classification* (Kaggle)
- **Objectif de performance** : accuracy $\approx$ 87–95 % (référence littérature)
- **Contrainte** : petit jeu de données (2 527 images), classe minoritaire *déchets divers* sous-représentée (5,4 %)

2. Data Collection

- Source : kaggle.com/datasets/asdasdasdasdas/garbage-classification
- Téléchargement via l'API Kaggle dans Google Colab (GPU T4)
- **2 527 images RGB**, résolution 512×384

Catégorie	Images
Papier	594
Verre	501
Plastique	482
Métal	410
Carton	403
Déchets	137
Total	2 527

3. Data Exploration




Figure: Répartition des images par catégorie





Figure: Un exemple par catégorie

Constat clé : fort déséquilibre sur la classe *déchets divers* ($\approx 5,4\%$) $\rightarrow$ motive l'augmentation ciblée (section 5).

4. Data Preprocessing / Cleaning

Pipeline en 2 volets :

- 1 **Standard** : redimensionnement 224×224 + normalisation $[0, 1]$ (puis normalisation ImageNet pour les modèles PyTorch)
- 2 **Morphologique** : niveaux de gris → seuillage d'Otsu → ouverture/fermeture morphologique (élément elliptique) → recadrage de l'objet



*Limite observée : le recadrage automatique échoue sur certaines images à faible contraste (verre/métal brillant)
— conservé comme démonstration, non appliqué systématiquement à l'entraînement.*

5. Data Augmentation

Objectif : compenser le déséquilibre de la classe *déchets divers* et améliorer la généralisation.

Transformations appliquées :

- Rotation aléatoire ($\pm 20^\circ$)
- Translation affine (10 %)
- Variation de luminosité ($\pm 0,2$)
- Recadrage aléatoire redimensionné
- Retournement horizontal

Appliquée uniquement sur les données d'entraînement, après le split (pour éviter la fuite de données).



Figure: Image originale et 5 versions augmentées

6. Split des données


Partitionnement stratifié 70/15/15

- **Entraînement** : 70 % (1 768 images)
 - **Validation** : 15 % (379 images)
 - **Test** : 15 % (380 images)
-
- Échantillonnage stratifié (`stratify=labels`) : préserve les proportions de chaque catégorie
 - Graine aléatoire fixée (`random_state=42`) pour la reproductibilité
 - **Point méthodologique important** : split effectué *avant* l'augmentation de données, pour qu'aucune version augmentée d'une image ne se retrouve à la fois en train et en test




7. Choix / conception du modèle

Trois architectures évaluées dans des conditions identiques :

- ❶ **CNN–Transformer hybride** : backbone EfficientNet-B0 (pré-entraîné) + tête MLP (256 → 6)
- ❷ **Apprentissage par transfert** : ResNet50 / MobileNetV3-Large (têtes de classification remplacées)
- ❸ **CNN personnalisé (from scratch)** : 3 blocs convolutifs (32→64→128 canaux), $\approx 0,1\text{M}$ paramètres





8. Évaluation avant optimisation (configuration manuelle)



Modèle hybride évalué **avant** optimisation des hyperparamètres (configuration manuelle par défaut) : précision de validation **95,25 %** dès les premières époques, faible écart train/val en fin d'entraînement.

9. Détail de la référence avant optimisation



Matrice de confusion et scores par classe du modèle en configuration manuelle (précision globale **95,25 %**) : confusions concentrées entre classes visuellement proches (verre/métal, plastique/métal) ; les scores F1 varient de 0,21 à 0,70, la classe *déchets* étant la plus faible (F1 $\approx 0,21$).

10. Optimisation des hyperparamètres (Optuna)




Optimisation bayésienne (TPE) sur l'espace $(lr, \lambda_{wd}) \in [10^{-5}, 10^{-2}] \times [10^{-6}, 10^{-2}]$, 10 essais de 3 époques chacun (sur un modèle proxy ResNet18).

Méthode	lr	wd	Acc. Val. (%)
Manuel (défaut)	1×10^{-3}	1×10^{-2}	95,25
Optuna (TPE)	$1,87 \times 10^{-3}$	$3,42 \times 10^{-4}$	95,25

Table: Comparaison des hyperparamètres et performances


- Optuna identifie une régularisation L2 plus faible ($3,42 \times 10^{-4}$ vs 10^{-2}), offrant une meilleure dynamique d'apprentissage.
- **Bénéfice** : convergence plus rapide et entraînement plus stable, sans dégradation de la précision maximale.

11. Évaluation Transfer Learning ResNet-18 (après Optuna)



ResNet-18 optimisé par Optuna : meilleure précision de validation **93,80 %** sur 12 époques. Sert de référence intermédiaire (modèle proxy) avant l'entraînement du modèle hybride final.

12. Dynamique d'entraînement du modèle proxy (ResNet-18)



Convergence plus rapide
dès les premières époques

Trajectoire Optuna plus
régulière, moins de pics



Stabilité améliorée
tout au long de l'entraînement

Ces deux courbes concernent le modèle proxy (ResNet-18) utilisé pendant la recherche d'hyperparamètres. La configuration Optuna démarre à un niveau plus élevé et maintient une convergence plus régulière.

13. Benchmarking matériel : CPU vs. GPU

Dispositif	Latence (ms)	Débit (img/s)
CPU (Colab)	83,78	11,9
GPU (T4)	3,53	283,4
Accél.	$\times 23,7$	$\times 23,8$

- GPU : latence **23,7**× plus faible.
- Débit GPU : **283,4 img/s** vs 11,9 img/s sur CPU.
- Précision inchangée : 93,9% sur les deux dispositifs.




14. Évaluation finale sur le jeu de test

Classe	Préc. (%)	Rappel (%)	F1 (%)
Carton	95,2	93,8	94,5
Verre	91,4	94,7	93,0
Métal	94,3	92,1	93,2
Papier	96,1	95,4	95,7
Plastique	93,7	91,8	92,7
Déchets	88,2	86,5	87,3
Moyenne pondérée	93,9	93,9	93,9

Table: Métriques détaillées par classe après optimisation


L'accuracy globale de **93,9%** sur le jeu de test confirme la robustesse du modèle. La classe *déchets divers* reste la plus difficile ($F1 = 87,3\%$), cohérent avec son sous-effectif initial (5,4%).

15. Tableau de bord final — modèle retenu



Meilleure précision de validation : **95,25 %** — benchmark du modèle hybride complet sur GPU NVIDIA T4 :
latence : **3,53 ms**, débit : **283,4 img/s**.

16. Exemples de prédictions du modèle final



Exemples qualitatifs de classification sur le jeu de test : comparaison entre l'étiquette réelle et l'étiquette prédite par le modèle final. La majorité des prédictions sont correctes ; les erreurs restantes concernent principalement la classe *déchets divers*, confondue avec du plastique ou du papier.

17. Discussion

Points forts

- L'optimisation bayésienne (Optuna) offre une convergence plus rapide et un entraînement plus stable (10 essais, ≈ 30 min-GPU)
- Le recadrage morphologique (Otsu) confirme les acquis du cours de traitement d'image, avec une analyse honnête de ses limites
- Accélération GPU $\times 23,7$: compatible temps réel
- Amélioration significative des scores F1 pour la classe déchets (de 0,21 à 87,3 %) grâce à l'optimisation

Limites

- Jeu de données restreint (2 527 images) $\rightarrow$ diversité visuelle limitée
- Classe *déchets divers* reste la plus faible (F1 = 87,3 %) malgré l'augmentation ciblée
- Une seule graine aléatoire — pas de validation croisée
- Aucune quantification post-entraînement testée (int8, ONNX, TFLite)

18. Conclusion et perspectives

Bilan

Pipeline complet (collecte → prétraitement → augmentation → 3 architectures → optimisation Optuna → benchmarking) ; **95,25 % en validation, 93,9 % sur test indépendant.**

Perspectives :

- Mixup / CutMix pour mieux traiter le déséquilibre de classes
- Extension de la recherche d'hyperparamètres (dropout, largeur du modèle)
- Quantification post-entraînement pour un déploiement embarqué
- Distillation de connaissances (Teacher-Student) pour un modèle ultra-léger, à l'image des travaux partagés par le professeur (ATMS-KD, GWOEdgeNet)

Merci de votre attention !